

Instituto Federal de Educação Ciência e Tecnologia de Goiás (IFG)

Alunos : Caio Teixeira Frauzino

Heuller César Gomes

Lara Souza Ribeiro Vargas e Aragão

Ronaldo Alves de Brito Pereira

Thiago da Silva Teixeira

Deep learning - Atividade Redes Recorrentes

Seja o conjunto de dados milk.csv que representa séries temporais da produção leiteira em 305 dias sobre 85 animais.

4 - Apresente a curva de Training Loss vs Validation Loss e sua interpretação.




Figura 1 - Curvas de Loss de treino e de validação para a execução padrão

Interpretação: Observa-se que a curva de validação ficou abaixo da curva de treinamento o que não é muito comum e isso pode ter ocorrido devido a divisão dos dados. É possível que os dados de validação sejam mais representativos do domínio do problema ou mais alinhados com as suposições do modelo e incorporem casos mais típicos em comparação aos dados de treinamento, fazendo com que o modelo apresente um desempenho superior na fase de validação.

Inicialmente, a Training Loss começou em um valor relativamente alto, refletindo o estágio inicial do treinamento, onde o modelo começou com pesos aleatórios e não conseguiu fazer previsões precisas. Nas primeiras épocas, houve uma queda acentuada na Training Loss,

indicando que o modelo estava aprendendo com os dados. No entanto, após esse período inicial, a Training Loss estabilizou em torno de um valor específico, e não houve mudança significativa a partir desse ponto. Isso sugere que o modelo pode ter atingido um platô ou um mínimo local, indicando que o aprendizado pode ser limitado. Por outro lado, a Validation Loss começou pequena e se estabilizou perto da Training Loss após algumas épocas, com pequenos picos de variação. Isso é um bom sinal, pois indica que o modelo está generalizando bem para dados não vistos. A proximidade entre a Validation Loss e a Training Loss sugere que o modelo não está sofrendo de overfitting significativo.

Em resumo, a interpretação específica dessas curvas indica que o modelo inicialmente aprendeu com os dados, mas depois parece ter atingido um limite em seu desempenho. Embora o modelo esteja generalizando bem, não há mais ganhos significativos na Training Loss, sugerindo que outras abordagens, como ajustes de arquitetura ou hiperparâmetros, podem ser necessárias para melhorar ainda mais o desempenho.

5 - Com a janela de tamanho 20, descreva o efeito de reduzir o número de neurônios da SimpleRNN de 25 para 2.




Figura 2 - Comparação das curvas de Loss de treino e de validação alterando a quantidade de neurônios na Camada SimpleRNN


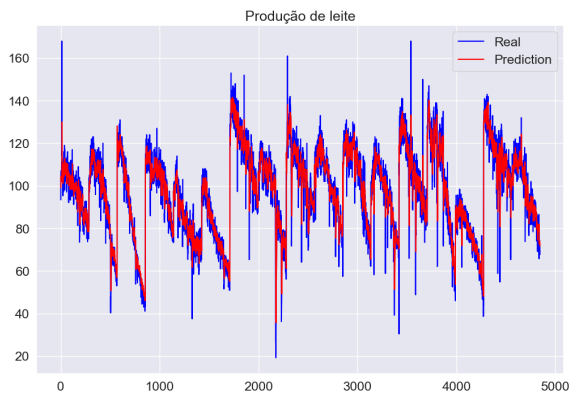



Figura 3 - Comparação das curvas de erro absoluto de treino e de validação alterando a quantidade de neurônios na Camada SimpleRNN



**Figura 4 - Gráfico comparativo dos valores esperados e preditos pela RNN
 Camada SimpleRNN com 25 neurônios**



**Figura 5 - Gráfico comparativo dos valores esperados e preditos pela RNN
 Camada SimpleRNN com 2 neurônios**




Figura 6 - Gráfico comparativo de faixa dos valores esperados e preditos pela RNN Camada SimpleRNN com 25 neurônios




Figura 7 - Gráfico comparativo de faixa dos valores esperados e preditos pela RNN Camada SimpleRNN com 2 neurônios

Interpretação: A redução drástica no número de neurônios de 25 para apenas 2 resultou em uma maior instabilidade durante o treinamento. Com uma quantidade menor de neurônios, a rede pode ter dificuldade em lidar com a variabilidade dos dados, levando a picos de maior perda durante o processo de validação. Esta instabilidade pode ser atribuída à limitada capacidade da rede para generalizar padrões com apenas dois neurônios, especialmente se os dados forem complexos. Em contraste, ao manter 25 neurônios, a rede pode ter sido mais capaz de lidar com essa complexidade, resultando em uma loss validation mais estável ao longo do tempo. Portanto, a instabilidade observada na loss validation de 2 neurônios sugere que a rede com 25 neurônios foi mais robusta e capaz de generalizar melhor para dados não vistos.

Apesar disso, ao observar os gráficos comparativos dos valores reais e preditos, constata-se que os resultados foram muito semelhantes, sugerindo que o modelo mais simples (com apenas 2 neurônios) pode ser suficiente para capturar a estrutura dos dados e fazer previsões precisas no caso estudado.

6 - Descreva o efeito de mudar a janela do RNN de tamanho 20 para 50.




Figura 8 - Comparação das curvas de Loss de treino e de validação alterando o tamanho da janela deslizante







Figura 9 - Comparação das curvas de erro absoluto de treino e de validação alterando o tamanho da janela deslizante




**Figura 10 - Gráfico comparativo dos valores esperados e preditos pela RNN
Janela Deslizante com 20 elementos**



**Figura 11 - Gráfico comparativo dos valores esperados e preditos pela RNN
Janela Deslizante com 50 elementos**



**Figura 12 - Gráfico comparativo de faixa dos valores esperados e preditos pela RNN
Janela Deslizante com 20 elementos**



**Figura 13 - Gráfico comparativo de faixa dos valores esperados e preditos pela RNN
Janela Deslizante com 50 elementos**

Interpretação: Ao aumentar a janela de 20 para 50 em uma rede recorrente, houve uma mudança notável no comportamento das curvas de Validation Loss e Training Loss. A Validation Loss, que representa o erro do modelo em um conjunto de dados de validação separado, ficou significativamente próxima da Training Loss, que reflete o erro durante o treinamento. Essa proximidade entre as duas curvas sugere que o modelo conseguiu generalizar bem para os dados de validação, à medida que a janela foi aumentada.

Uma janela maior pode ter permitido que o modelo capturasse mais informações e padrões nos dados de treinamento, o que facilitou uma melhor generalização para os dados de validação. Esse alinhamento próximo entre Training Loss e Validation Loss indica que o modelo não está sofrendo de overfitting. A observação de que as duas curvas estão próximas

sugere que o modelo está aprendendo de forma geral e está se ajustando bem tanto aos dados de treinamento quanto aos de validação. Esses resultados são encorajadores e sugerem que o aumento da janela ajudou o modelo a aprender de maneira mais eficaz.

7 - Descreva o efeito de mudar a janela do RNN de tamanho 20 para 5.




Figura 14 - Comparação das curvas de Loss de treino e de validação alterando o tamanho da janela deslizante


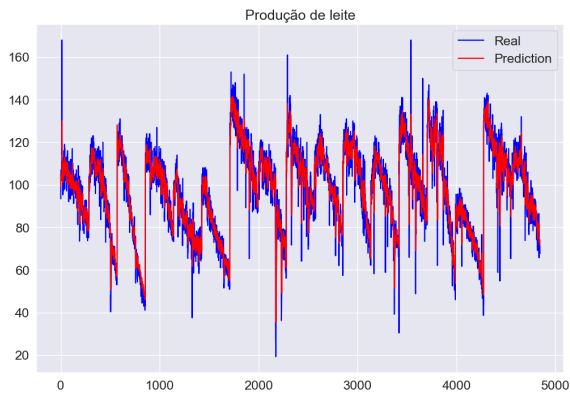




Figura 15 - Comparação das curvas de erro absoluto de treino e de validação alterando o tamanho da janela deslizante




**Figura 16 - Gráfico comparativo dos valores esperados e preditos pela RNN
Janela Deslizante com 20 elementos**



**Figura 17 - Gráfico comparativo dos valores esperados e preditos pela RNN
Janela Deslizante com 5 elementos**



**Figura 18 - Gráfico comparativo de faixa dos valores esperados e preditos pela RNN
Janela Deslizante com 20 elementos**



**Figura 19 - Gráfico comparativo de faixa dos valores esperados e preditos pela RNN
Janela Deslizante com 5 elementos**

Interpretação: Quando a janela da rede recorrente foi reduzida de 20 para 5, observamos uma mudança sutil nas curvas de Training Loss e Validation Loss. A curva de treinamento se apresentou de forma mais suave e o número de epochs até a sua estabilidade aumentou, mas o valor da loss não ficou muito distante do obtido com a janela de 20. Já a Validation Loss apresentou mais picos de erro após a redução da janela. Isso indica que o modelo se tornou mais sensível a variações nos dados de validação, o que pode ser atribuído à redução da janela. Com uma janela menor, o modelo pode ter encontrado mais dificuldade em generalizar padrões e, conseqüentemente, tornou-se mais suscetível a picos de erro nos dados de validação.